
Ecole Marocaine des Sciences de l'Ingenieur

Honoris United Universities — EMSI Rabat

Filière : Intelligence Artificielle & Science des Données

4^e année — IASD

Rapport de Stage

▷ **Projet *AutoFlow* — version concise et visuelle**

**AutoFlow : Système d'Automatisation
Intelligent des Workflows d'Entreprise**

Cas d'application : agence de location de voitures — Rabat

Intitulé du stage : *AI Engineer — automatisation des workflows métier*

Encadrant académique : *Encadrant académique à compléter*

Tuteur entreprise : *Tuteur entreprise à compléter*

Entreprise d'accueil : *Structure d'accueil à compléter*

Réalisé par :

Nom et prénom à compléter

Soutenue publiquement le : _____

Résumé exécutif

Problème

Une agence reçoit des demandes sur des canaux dispersés. Les informations sont incomplètes, la disponibilité est vérifiée manuellement et les relances peuvent être oubliées. Ces frictions sont des hypothèses d'audit à vérifier sur site, non des constats chiffrés sur une agence réelle.

Contribution

AutoFlow est un workflow supervisé : un orchestrateur LangGraph coordonne trois agents spécialisés (comprendre, vérifier, préparer), applique une matrice d'escalade et se suspend pour une décision humaine. La disponibilité est calculée par code ; le système ne transmet jamais de message au client sans clic humain.

Niveau de preuve

Les résultats de validation concernent un jeu fictif contrôlé : 16 tests automatisés et 45 messages étiquetés. Les effets sur les délais, les ventes ou la charge de travail doivent être mesurés durant un pilote avant toute conclusion métier.

Table des matières

Résumé exécutif	1
1 Contexte et problématique	6
1.1 Le point de départ	6
1.2 Du chaos opérationnel au workflow supervisé	7
1.3 Six frictions à mesurer pendant l'audit	8
1.4 Problématique et invariants	9
2 État de l'art et choix techniques	10
2.1 Choisir une orchestration plutôt qu'une conversation libre	10
2.2 Pourquoi LangGraph ?	11
2.3 Règles d'abord, LLM optionnel	12
2.4 Critères de décision et limites	13
3 Analyse des besoins	14
3.1 Acteurs et responsabilités	14
3.2 Exigences fonctionnelles	15
3.3 Périmètre V1	16
3.4 Cadre de mesure du pilote	17
4 Conception architecturale	18
4.1 Vue conteneurs	18
4.2 Graphe et contrôle humain	19
4.3 États et transitions légales	20
4.4 Séquence d'un cas sensible et déploiement	21
5 Réalisation du workflow supervisé	23
5.1 Trois agents, une responsabilité chacun	23
5.2 Expliquer le traitement	24
5.3 Gestion d'un scénario riche	25
5.4 Difficultés rencontrées et corrections	26
6 API et expérience opérateur	27
6.1 La file de validation	27
6.2 Le suivi en direct	28
6.3 Les simulations métier	29
6.4 API, données et sécurité	30
7 Évaluation, limites et perspectives	31
7.1 Méthode de validation	31
7.2 Lecture correcte des résultats	32
7.3 Limites et gestion des risques	33
7.4 Bilan et feuille de route	34
Conclusion générale	35

Bibliographie sélective	36
--------------------------------	-----------

A Reproduction et fichiers fournis	37
---	-----------

Table des figures

1.1	Du problème opérationnel à la réponse AutoFlow : structurer, vérifier, préparer et tracer.	7
2.1	Graphe d'orchestration : les agents proposent, l'orchestrateur route et l'humain décide.	11
3.1	Vue contexte : la frontière du système exclut tout envoi client automatique.	14
4.1	Conteneurs : interface React, API FastAPI, orchestrateur, agents, règles et persistance.	18
4.2	Le graphe LangGraph réel : chemins standard, exceptions et interruption humaine. .	19
4.3	Machine à états : les alertes et les états terminaux restent explicitement distincts. . .	20
4.4	Scénario C : une demande ambiguë avec remise nécessite deux décisions humaines. .	21
4.5	Options de déploiement : poste de démonstration, cloud pilote et mode serverless à contraintes explicites.	21
5.1	Trace explicable : évènements, chemin exécuté, valeurs, seuils et branche de décision.	24
5.2	Une séquence qui démontre la reprise après complétion des données puis l'escalade de remise.	25
6.1	Schéma de la file : priorité, niveau de revue, motif et actions avant toute sortie client.	27
6.2	Un écran de supervision rend le raisonnement consultable : événement, état, règle et seuil.	28
6.3	Sept cas opérationnels servent à la démonstration et à la validation d'acceptation. .	29
7.1	Les simulations relient l'exigence métier, l'exécution API et une assertion vérifiable.	32

Liste des tableaux

1.1	Hypothèses de friction métier.	8
2.1	Comparaison de familles d'outils.	10
2.2	Répartition des responsabilités.	12
3.1	Acteurs du workflow.	14
3.2	Exigences centrales et preuve associée.	15
3.3	Indicateurs à mesurer, pas à promettre.	17
5.1	Contrat des agents.	23
5.2	Exemples de corrections découvertes par les simulations.	26
6.1	Contrat API et séparation des données.	30
7.1	Résultats reproductibles sur le jeu contrôlé.	31
7.2	Limites déclarées et prochaine preuve nécessaire.	33

Chapitre 1

Contexte et problématique

1.1 Le point de départ

AutoFlow étudie le traitement de demandes de location de voitures dans une PME de services à Rabat. Le projet ne cherche pas à remplacer la relation client : il rend visible une prochaine action, prépare le travail répétitif et conserve la décision commerciale à l'équipe.

Entrées

WhatsApp, réseaux sociaux, téléphone, formulaire, comptoir.

Traitement

Compréhension du message, contrôle de disponibilité, préparation d'un brouillon, validation humaine.

Sorties

Brouillon, escalade, relance planifiée, journal d'évènements, tableau de bord.

À retenir

La valeur recherchée n'est pas une réponse automatique : c'est une coordination fiable entre les messages, les règles métier et les personnes.

1.2 Du chaos opérationnel au workflow supervisé




Figure 1.1 – Du problème opérationnel à la réponse AutoFlow : structurer, vérifier, préparer et tracer.

1.3 Six frictions à mesurer pendant l’audit

Table 1.1 – Hypothèses de friction métier.

Friction	Risque opérationnel
F1 Demandes dispersées	Re-saisie, oubli, information perdue
F2 Disponibilité manuelle	Réponse lente, conflit de réservation
F3 Questions répétitives	Attention de l’équipe consommée
F4 Relances oubliées	Devis non suivis
F5 Statut incertain	Coordination par mémoire ou messages
F6 Faible visibilité	Pilotage sans trace exploitable

Prudence méthodologique

Ces frictions guident le prototype. Elles doivent être confirmées par observation, entretien et mesure avant/après.

1.4 Problématique et invariants

Question de recherche

Comment transformer des demandes clients hétérogènes en un workflow d'aide à la décision qui accélère le traitement sans déléguer une décision sensible à un modèle ?

1. **Aucun message client n'est envoyé seul.** Une décision humaine est requise.
2. **Aucune disponibilité n'est inventée.** Le calcul est déterministe, séparé du LLM.
3. **Toute décision est traçable.** Les transitions créent des événements horodatés et justifiés.

À retenir

Ces invariants transforment la confiance en propriété vérifiable du système, pas en promesse de marketing.

Chapitre 2

État de l’art et choix techniques

2.1 Choisir une orchestration plutôt qu’une conversation libre

Un agent LLM autonome est inadapté lorsqu’une erreur affecte un prix, une réservation ou une réclamation. AutoFlow utilise un graphe d’états explicite : un noeud a une responsabilité, une transition a une raison, et un humain peut interrompre puis reprendre l’exécution.

Table 2.1 – Comparaison de familles d’outils.

Approche	Atout	Limite pour AutoFlow
RPA / low-code	Connecteurs rapides	État métier et règles complexes limités
LLM autonome	Langage naturel flexible	Risque d’invention ou d’action non contrôlée
Multi-agent conversationnel	Rôles rapides à prototyper	Coordination implicite, audit difficile
Graphe supervisé	États, pauses, reprise, trace	Conception initiale plus exigeante

2.2 Pourquoi LangGraph ?

Propriétés recherchées

- StateGraph rend les branches et les sorties visibles.
- `interrupt()` suspend le travail au point de contrôle humain.
- `Command(resume)` reprend la même demande grâce au `thread_id` et au checkpoint.
- Le graphe publié par l'API peut être comparé au code et à l'interface.




Figure 2.1 — Graphe d'orchestration : les agents proposent, l'orchestrateur route et l'humain décide.

2.3 Règles d'abord, LLM optionnel

Table 2.2 – Répartition des responsabilités.

Composant	Décision	Garantie recherchée
Intake	Message vers données structurées	Preuve textuelle et confiance par champ
Disponibilité	Véhicules et alternatives	Chevauchements, tampon, maintenance : code déterministe
Suivi	Brouillon et relance	Prix injecté depuis les données ; aucun envoi autonome
Orchestrateur	Routage et escalade	États légaux, motifs et acteurs journalisés

Evidence gate

Un champ proposé par un LLM est rejeté si son passage justificatif n'est pas présent dans le message source.

2.4 Critères de décision et limites

1. **Fiabilité** : les règles métier et les seuils sont versionnés dans `rules.json`.
2. **Explicabilité** : le panneau de trace donne la règle, la valeur et la branche.
3. **Réversibilité** : agents Python purs ; stockage SQLite en pilote, PostgreSQL possible ensuite.
4. **Conformité** : minimisation des données, téléphones masqués dans les données fictives et validation humaine des actions sensibles.

À retenir

Le choix technique est justifié par des propriétés observables dans le dépôt, pas par des compteurs de popularité ou des promesses de modèle.

Chapitre 3

Analyse des besoins

3.1 Acteurs et responsabilités

Table 3.1 – Acteurs du workflow.

Acteur	Attend du système	Reste responsable de
Client	Une réponse claire et cohérente	Ses informations et son choix
Équipe	Une file priorisée et un brouillon	Relecture, modification, envoi
Manager	Les exceptions visibles	Prix, remise, réclamation, clôture
Administrateur	Des règles et une trace	Paramétrage et confidentialité




Figure 3.1 – Vue contexte : la frontière du système exclut tout envoi client automatique.

3.2 Exigences fonctionnelles

Table 3.2 – Exigences centrales et preuve associée.

ID	Exigence	Preuve dans le projet
RF1	Structurer une demande	Agent Intake et tests de scénario
RF2	Vérifier ou proposer une alternative	Agent Availability déterministe
RF3	Préparer un brouillon et une relance	Agent FollowUp et journal
RF4	Escalader une réclamation	Scénario de réclamation
RF5	Escalader les cas sensibles	Matrice d'escalade et interruption
RF6	Ne rien envoyer automatiquement	Décision humaine requise
RF7	Planifier les relances	Horloge de démo et tests
RF8	Tracer les transitions	Table d'évènements

3.3 Périmètre V1

Inclus

Formulaire public, saisie manuelle, webhook n8n, trois agents, orchestrateur, file de validation, suivi en direct, simulations, règles et gestion de flotte, journal d'évènements, import Excel.

Webhook n8n validé de bout en bout

Le workflow publié AutoFlow - Demo local intake webhook a été exécuté sur `/webhook/autoflow-demo-intake`. Il a créé la demande A-0055 via la vraie API AutoFlow. Le protocole de rejeu et la réponse sont fournis dans `integrations/n8n/VERIFICATION_WEBHOOK.md`.

Exclu volontairement

Paiement, tarification dynamique, connecteur WhatsApp réel, CRM/ERP, voix, maintenance prédictive, et tout envoi autonome. Une intégration ne sera ajoutée qu'après audit de besoin.

3.4 Cadre de mesure du pilote

Table 3.3 – Indicateurs à mesurer, pas à promettre.

Indicateur	Source	Comparaison pilote
Temps de première réponse	événements / brouillons	avant vs après
Délai de devis	<code>received_at</code> → <code>quote_ready</code>	avant vs après
Demandes complètes	données structurées	taux par canal
Relances effectuées	<code>follow_ups</code>	réalisées / dues
Charge manuelle	observation et chronométrage	minutes / demande

À retenir

Le pilote doit mesurer le travail déplacé vers l'humain autant que le temps économisé.

Chapitre 4

Conception architecturale

4.1 Vue conteneurs




Figure 4.1 – Conteneurs : interface React, API FastAPI, orchestrateur, agents, règles et persistance.

4.2 Graphe et contrôle humain




Figure 4.2 – Le graphe LangGraph réel : chemins standard, exceptions et interruption humaine.

4.3 États et transitions légales




Figure 4.3 — Machine à états : les alertes et les états terminaux restent explicitement distincts.

4.4 Séquence d'un cas sensible et déploiement




Figure 4.4 – Scénario C : une demande ambiguë avec remise nécessite deux décisions humaines.




Figure 4.5 – Options de déploiement : poste de démonstration, cloud pilote et mode serverless à contraintes explicites.

Le diagramme de séquence est la preuve narrative : le système vérifie avant de préparer, et une personne valide avant d'agir.

Chapitre 5

Réalisation du workflow supervisé

5.1 Trois agents, une responsabilité chacun

Table 5.1 – Contrat des agents.

Agent	Entrée / sortie	Contrôle principal
Intake	Message → structure, confiance, preuves	Champs manquants ou incertains → humain
Availability	Structure + flotte → options / raisons	Calcul déterministe, pas de LLM
FollowUp	Offre vérifiée → brouillon / action	Prix de la base ; envoi hors de l'agent

Orchestrateur

Il ne négocie ni ne rédige une décision commerciale. Il applique la machine d'états, les seuils, la matrice d'escalade et le checkpoint ; il journalise ensuite le chemin emprunté.

5.2 Expliquer le traitement




Figure 5.1 — Trace explicable : évènements, chemin exécuté, valeurs, seuils et branche de décision.

5.3 Gestion d'un scénario riche




Figure 5.2 — Une séquence qui démontre la reprise après complétion des données puis l'escalade de remise.

1. Dates ambiguës : le workflow prépare une question, puis s'interrompt.
2. L'équipe complète les champs : la disponibilité est recalculée sur les informations corrigées.
3. Remise demandée : le manager valide ou refuse la proposition avant qu'un brouillon puisse être envoyé.

5.4 Difficultés rencontrées et corrections

Table 5.2 – Exemples de corrections découvertes par les simulations.

Défaut	Risque	Correction
Horloge de relance réinitialisée	Un lead ne devenait jamais stalled	Référence conservée sur la première réponse
Intention information mal priorisée	Routage vers réservation	Règle ajoutée sur la formulation de question
Token des tests ancien	Régression cachée après changement de configuration	Token isolé, injecté par les tests

À retenir

Les simulations sont une forme de test d'acceptation : un parcours affiché à l'écran doit aussi passer dans la suite automatisée.

Chapitre 6

API et expérience opérateur

6.1 La file de validation




Figure 6.1 — Schéma de la file : priorité, niveau de revue, motif et actions avant toute sortie client.

6.2 Le suivi en direct




Figure 6.2 — Un écran de supervision rend le raisonnement consultable : évènement, état, règle et seuil.

6.3 Les simulations métier

Simulations métier — démontrer avec des cas jouables

Sept scénarios d'acceptation pilotent la vraie API ; une divergence à l'écran devient un test à corriger.

Tester le système
Chaque carte décrit un cas métier, les étapes attendues et le résultat vérifié.

▶ TOUT JOUER

WHATSAPP · STANDARD Devis disponible CIT-03 libre → brouillon → relance +24 h ✓ PASSÉ JOUER	FACEBOOK · ALTERNATIVE Véhicule indisponible Alternative expliquée, motif de refus visible ✓ PASSÉ JOUER	INSTAGRAM · SENSIBLE Dates ambiguës + remise Deux interruptions, validation manager ✓ PASSÉ JOUER
SITE WEB · RÉCLAMATION Cas urgent Aucun brouillon, escalade immédiate ✓ PASSÉ JOUER	TÉLÉPHONE · RELANCE Lead silencieux +24 h, puis +72 h → appel recommandé ✓ PASSÉ JOUER	COMPTOIR · INFORMATION Question simple Réponse préparée sans décision commerciale ✓ PASSÉ JOUER

La septième simulation vérifie le refus d'une location longue ; l'ensemble complète la suite de 16 tests automatisés.

Figure 6.3 — Sept cas opérationnels servent à la démonstration et à la validation d'acceptation.

6.4 API, données et sécurité

Table 6.1 – Contrat API et séparation des données.

Élément	Règle
Administration	Token dans l'en-tête X-Admin-Token ; les tests injectent leur propre token.
Formulaire public	Entrée de demande uniquement ; pas d'accès aux données d'administration.
Journal	Évènements, brouillons, revues et relances permettent le calcul d'indicateurs.
Données de V1	Jeu fictif généré, utilisé pour démonstration et évaluation contrôlée.
Import Excel	Données d'agence chargées pour l'interface ; non utilisées pour publier les métriques de V1.

À retenir

La sécurité et la qualité du rapport reposent sur une même séparation : configuration, données d'interface et données d'évaluation ne doivent pas être confondues.

Chapitre 7

Évaluation, limites et perspectives

7.1 Méthode de validation

Trois niveaux de preuve

1. Implémentation : tests end-to-end et simulations. **2. Qualité d'extraction** : comparaison aux étiquettes du jeu fictif. **3. Impact métier** : protocole avant/après à exécuter en pilote ; aucun gain n'est déclaré avant cette mesure.

Table 7.1 – Résultats reproductibles sur le jeu contrôlé.

Mesure	Résultat	Périmètre
Tests automatisés	16 passed	workflow + simulations/catalogue
<code>pickup_date</code>	39/44 (89%)	demandes devis / modification
<code>return_date</code>	36/44 (82%)	demandes devis / modification
<code>vehicle_category</code>	40/44 (91%)	demandes devis / modification
Intention	45/45 (100%)	45 messages fictifs
Erreurs observées routées à l'humain	8/8	même échantillon

7.2 Lecture correcte des résultats



Figure 7.1 — Les simulations relient l'exigence métier, l'exécution API et une assertion vérifiable.

Ce que les résultats ne prouvent pas

Ils ne démontrent ni un gain de vente, ni un gain de temps en agence, ni une performance LLM sur des messages réels. Les messages et étiquettes sont issus du même générateur ; le résultat est donc optimiste par construction.

7.3 Limites et gestion des risques

Table 7.2 – Limites déclarées et prochaine preuve nécessaire.

Limite	Étape suivante
Échantillon fictif et petit	30 messages réels anonymisés, annotés indépendamment
Moteur LLM non évalué en situation	Essai contrôlé avec journal de correction humaine
Pas de KPI métier réel	Audit court puis pilote de 2–4 semaines
Connecteurs réels exclus	Notification interne d’abord, jamais envoi autonome
Configuration locale	Déploiement pilote avec secrets et volume persistant

7.4 Bilan et feuille de route

1. **Audit** : suivre cinq demandes réelles, cartographier les canaux et mesurer la ligne de base.
2. **Pilote** : utiliser AutoFlow en observation, comparer délais, complétude et relances ; garder l’envoi humain.
3. **Décision** : poursuivre uniquement si l’équipe confirme une valeur opérationnelle et un niveau de confiance acceptable.
4. **Évolution** : connecter les canaux en périphérie, renforcer la confidentialité, puis étudier la généralisation à un autre métier.

À retenir

La contribution principale n’est pas un modèle nouveau ; c’est une discipline d’AI engineering : métiers, règles, contrôle humain, mesures et traces.

Conclusion générale

AutoFlow montre comment une demande client peut devenir un workflow explicable sans devenir une décision autonome. L'architecture compacte, le calcul déterministe de disponibilité, la validation humaine et le journal d'évènements fournissent une base crédible pour un pilote. Le rapport fait une distinction volontaire entre ce qui est implémenté, ce qui est validé dans un environnement contrôlé et ce qui reste à mesurer en agence.

Message final pour le jury

Le système ne promet pas de remplacer l'équipe. Il rend le travail visible, vérifiable et plus facile à coordonner ; l'équipe conserve la responsabilité des décisions commerciales.

Bibliographie sélective

1. LangChain, *LangGraph documentation — interrupts, persistence and human-in-the-loop*, documentation officielle, consultée le 25 septembre 2026. <https://docs.langchain.com/oss/python/langgraph/interrupts>
2. FastAPI, *FastAPI documentation*, documentation officielle, consultée le 25 septembre 2026. <https://fastapi.tiangolo.com/>
3. S. Brown, *The C4 model for visualising software architecture*. <https://c4model.com/>
4. National Institute of Standards and Technology, *AI Risk Management Framework (AI RMF 1.0)*, NIST AI 100-1, 2023.
5. B. Amershi et al., *Guidelines for Human-AI Interaction*, CHI, 2019.
6. Royaume du Maroc, *Loi n° 09-08 relative à la protection des personnes physiques à l'égard du traitement des données à caractère personnel*, 2009.
7. Documentation interne : docs/00-CONTEXTE.md, docs/02-architecture.md, docs/05-evaluation.md, backend/eval/report.md.

Annexe A

Reproduction et fichiers fournis

Compilation Overleaf

Téléverser ce fichier ou `rapport.tex` avec le dossier complet `rapport_assets/`. Choisir pdfLaTeX. Les logos officiels sont facultatifs : le document compile avec un fallback textuel.

Validation du prototype

Depuis backend/ : ..

`.venv`

Scripts

`python.exe -m pytest -q`, puis `python -m eval.eval_intake`. Les commandes et la provenance des figures sont détaillées dans `rapport_assets/README.md`.